Materiały do przedmiotu:

Data Mining

Laboratorium nr 2

Przygotowanie i wstępna obróbka danych

Autor:

Marcin Matczuk

Fundusze Europejskie dla Rozwoju Społecznego

Rzeczpospolita Polska

Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

Spis treści

Wprowadzenie **3**
Cel laboratorium **6**
Instrukcja laboratoryjna **6**
Ćwiczenia samodzielne **14**
Pytania pomocnicze **16**
Podsumowanie **16**
Literatura **16**

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

Wprowadzenie

W niniejszym laboratorium kontynuowana jest analiza zbioru danych „UCI Online Retail II", rozpoczęta na poprzednich zajęciach. Tym razem uwaga zostanie skupiona na dokładniejszym rozpoznaniu typów transakcji, agregowaniu danych oraz analizie zależności występujących między wybranymi zmiennymi.

W pierwszej części laboratorium poszczególne rekordy zostaną przypisane do określonych kategorii transakcji. Pozwoli to w łatwy sposób rozróżnić typy transakcji, np. w celu wyznaczenia podstawowych statystyk dla każdego z nich. Warunki klasyfikacji wynikną z przeprowadzonej eksploracji danych.

Kolejno utworzona zostanie ramka danych zawierająca zagregowane informacje o klientach. Na jej podstawie omówione zostaną zagadnienia korelacji, macierzy korelacji oraz jej wizualnego przedstawienia za pomocą mapy cieplnej (ang. „heatmap").

Korelacja jest pojęciem statystycznym opisującym zależność między dwiema zmiennymi losowymi. Na potrzeby tego kursu pojęcie korelacji zawęzimy do zależności liniowej. Jest to pewne uproszczenie, gdyż ogólne pojęcie korelacji może odnosić się również do zależności nieliniowych.

Do badania siły i kierunku zależności liniowej między zmiennymi losowymi będziemy wykorzystywać współczynnik korelacji liniowej Pearsona (ang. „Pearson correlation coefficient", PCC). Dla dwóch zmiennych losowych X i Y współczynnik korelacji Pearsona definiuje się następująco:

$$\rho_{XY} = \frac{\operatorname{cov}(X,Y)}{\sigma_X \cdot \sigma_Y},$$

gdzie:

- $\operatorname{cov}(X,Y)$ oznacza kowariancję zmiennych losowych X i Y,
- σ_X i σ_Y oznaczają odchylenia standardowe odpowiednio zmiennej losowej X i Y.

Dla skończonego zbioru N par obserwacji (x_i, y_i), $i = 1,2,\dots,N$, współczynnik korelacji liniowej Pearsona przyjmuje postać:

$$r_{XY} = \frac{\sum_{i=1}^{N}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{N}(x_i - \bar{x})^2 \sum_{i=1}^{N}(y_i - \bar{y})^2}},$$

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

gdzie symbole $\bar{x}$ i $\bar{y}$ oznaczają wartość średnią odpowiednio cechy x oraz y.

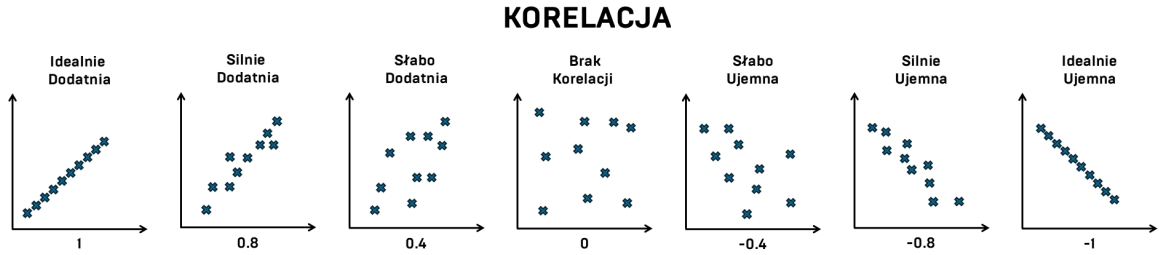
Kowariancja natomiast w przypadku skończonego zbioru N par obserwacji (x_i, y_i), $i = 1,2, \dots, N$, można wyrazić poprzez wzór:

$$\operatorname{cov}(X,Y) = \frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})(y_i - \bar{y}).$$

Korelację Pearsona można traktować jako znormalizowaną kowariancję. Dzięki podzieleniu przez odchylenia standardowe wynik nie zależy od jednostek i zawsze mieści się w przedziale $[-1,1]$. Jednak to właśnie kowariancja niesie informację o kierunku wspólnej zmienności:

- $\operatorname{cov}(X,Y) > 0$ – oznacza, że gdy X rośnie, Y ma również tendencję wzrostową, lub że gdy X maleje, Y ma również tendencję malejącą
- $\operatorname{cov}(X,Y) < 0$ – oznacza, że gdy X rośnie, Y ma tendencję malejącą, lub że gdy X maleje, Y ma tendencję rosnącą.
- $\operatorname{cov}(X,Y) \approx 0$ – oznacza brak wyraźnej zależności liniowej.

Korelacja zachowuje znak kowariancji, ale dodatkowo skaluje jej wartość. Dlatego kowariancja mówi o kierunku, natomiast korelacja mówi zarówno o kierunku, jak i o sile zależności liniowej w skali od –1 do 1. Na rysunku 2.1 przedstawiono kilka zbiorów dwuwymiarowych punktów o odmiennych korelacjach.



Rysunek 2.1. Graficzne przedstawienie kilku dwuwymiarowych zbiorów punktów o różnych wartościach współczynnika korelacji Pearsona.

Rozmawiając o korelacji, kluczowe jest zrozumienie, iż nie dowodzi ona istnienia związku przyczynowo-skutkowego między zmiennymi. Wiele zjawisk może wykazywać silną korelację, mimo że jedno z nich nie jest przyczyną drugiego. Przykładem może być zależność między sprzedażą lodów a liczbą utonięć. Obie wartości zwykle rosną latem, jednak ich współwystępowanie wynika przede wszystkim z wpływu trzeciego czynnika, na przykład wysokiej temperatury.

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

W przypadku szeregów czasowych, czyli danych uporządkowanych zgodnie z upływem czasu, pojawia się dodatkowe pojęcie autokorelacji. Dla szeregu czasowego lub sygnału dyskretnego autokorelacja dla opóźnienia $k \in \mathbb{N}_0$ określa wartość współczynnika korelacji Pearsona między szeregiem a jego kopią przesuniętą o k jednostek czasu. Można ją interpretować jako miarę liniowego związku między wartością x_t a wcześniejszą wartością x_{t-k} tego samego szeregu.

Niech X_t oznacza zmienną losową opisującą możliwe wartości procesu w chwili t, wtedy autokorelację o opóźnieniu k definiuje się następująco:

$$R(k) = \frac{\operatorname{cov}(X_t, X_{t-k})}{\operatorname{std}(X_t) \cdot \operatorname{std}(X_{t-k})},$$

gdzie:

- $\operatorname{cov}(X_t, X_{t-k})$ oznacza kowariancję zmiennych losowych X_t i X_{t-k} opisujących możliwe wartości procesu w chwili t oraz $t-k$,
- $\operatorname{std}(X_t)$ i $\operatorname{std}(X_{t-k})$ oznaczają odchylenia standardowe odpowiednio zmiennej losowej X_t i X_{t-k}.

Warto odnotować, że w tym przypadku X_t nie oznacza pojedynczej zaobserwowanej liczby. Na przykład X_t może oznaczać temperaturę urządzenia po t minutach pracy. Uruchamiamy urządzenie 1000 razy i za każdym razem mierzymy temperaturę dokładnie po 10 minutach. W ten sposób tworzy się próbę w chwili $t = 10$, na podstawie której oblicza się odchylenie standardowe oraz inne potrzebne statystyki.

Ostatni segment laboratorium będzie poświęcony analizie przychodów w ujęciu miesięcznym. Utworzony zostanie szereg czasowy umożliwiający ocenę sezonowości sprzedaży oraz porównanie wyników osiąganych w kolejnych miesiącach. Dane zostaną również przedstawione w formie graficznej, co ułatwi interpretację zmian zachodzących w czasie.

W trakcie laboratorium zostaną zrealizowane następujące zadania: klasyfikacja różnych rodzajów transakcji, agregacja danych i wyznaczenie podstawowych statystyk opisowych, analiza miesięcznych przychodów oraz ocena występowania sezonowości, wyznaczenie macierzy korelacji, a także analiza autokorelacji dla wybranych wartości opóźnienia.

Laboratorium przewidziane jest na dwie godziny lekcyjne.

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

Cel laboratorium

Celem laboratorium jest rozwinięcie umiejętności eksplorowania i przekształcania danych, a także interpretowania wyników w kontekście procesów biznesowych.

Po zrealizowaniu laboratorium czytelnik będzie potrafił formułować pytania i hipotezy dotyczące danych, agregować dane i wyznaczać podstawowe statystyki opisowe, analizować przychody w ujęciu miesięcznym oraz rozpoznawać potencjalne efekty sezonowości, a także obliczać i interpretować współczynnik korelacji Pearsona.

Instrukcja laboratoryjna

Do wykonania ćwiczeń opisanych w instrukcji wymagane jest środowisko programistyczne obsługujące język Python w wersji 3.12.4 lub nowszej. Ponadto należy zainstalować następujące pakiety: pandas, numpy, seaborn, matplotlib.

Rekomendowanym środowiskiem programistycznym jest Visual Studio Code (**https://code.visualstudio.com/**) wraz z rozszerzeniem Jupyter (**https://jupyter.org/**).

Należy dokładnie przeanalizować kod przedstawiony w listingach, a następnie przenieść go do własnego programu, uruchomić, oraz zweryfikować poprawność otrzymanych wyników.

W niniejszym laboratorium ponownie korzystamy ze zbioru danych „UCI Online Retail II", dostępnego m.in. w serwisie „Kaggle" (**https://www.kaggle.com/datasets/jillwang87/online-retail-ii**). Pomimo że zbiór ten był już wykorzystywany w laboratorium nr 1, warto przypomnieć jego charakterystykę.

Zbiór „UCI Online Retail II" zawiera informacje o transakcjach przeprowadzonych przez brytyjskie przedsiębiorstwo prowadzące sprzedaż internetową, którego klientami są głównie hurtownicy. Dane zostały podzielone na dwa zestawy. Pierwszy z nich obejmuje okres od 1 grudnia 2009 r. do 9 grudnia 2010 r., natomiast drugi — od 1 grudnia 2010 r. do 9 grudnia 2011 r. Oba pliki znajdują się w folderze „Materiały" dołączonym do laboratorium.

Pracę rozpoczynamy od wczytania obu zestawów danych do obiektów typu „DataFrame" (ramka danych) za pomocą biblioteki „pandas" – analogicznie jak w

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

laboratorium nr 1. Następnie łączymy oba obiekty w jeden zbiór danych, korzystając z funkcji „pandas.concat". Listing 2.1 przedstawia ten proces.

Listing 2.1. Wczytywanie zbioru danych do programu.

```
1.  import pandas as pd
2.
3.  transakcje_09_10 = pd.read_csv('Materiały/online_retail_09_10.csv', sep=',')
4.  transakcje_10_11 = pd.read_csv('Materiały/online_retail_10_11.csv', sep=',')
5.
6.  transakcje = pd.concat(
7.                  [transakcje_09_10, transakcje_10_11], ignore_index=True)
```

Naszym pierwszym celem jest kontynuacja eksploracji transakcji rozpoczętej w poprzednim laboratorium. Dotychczasowa analiza wykazała, że zbiór „UCI Online Retail II" zawiera nie tylko standardowe transakcje sprzedaży, lecz także zwroty, anulowane faktury oraz wewnętrzne korekty stanów magazynowych. Nie są to jednak wszystkie możliwe typy.

Dokładniejsza analiza danych pozwala zauważyć kolejną interesującą zależność. Mianowicie, niektóre produkty, gdy dotyczą ich faktury bez numeru klienta, mają wyższą cenę jednostkową niż w przypadku faktur zawierających taki numer. W obu przypadkach wartość zmiennej „Quantity" jest większa od zera, a zatem obserwacje te nie dotyczą zwrotów. Wynik przedstawiony na listingu 2.2 ilustruje opisaną sytuację.

Listing 2.2. Pobranie informacji o transakcjach dotyczących produktu o numerze 84598.

```
1.  produkt_84598 = transakcje[transakcje['StockCode'] == '84598']
2.  print(produkt_84598[['Quantity','UnitPrice','CustomerID']][:25])
```

Analizując wynik działania kodu przedstawionego na listingu 2.2, możemy zauważyć, że cena jednostkowa produktu różni się w zależności od tego, czy do transakcji przypisano numer klienta. W przypadku produktu o numerze 84598 cena jednostkowa wynosi 0.21, gdy numer klienta jest podany, oraz 0.43, gdy w kolumnie „CustomerID" brakuje tej informacji.

Sprawdźmy, czy zaobserwowana zależność nie ma wyłącznie charakteru lokalnego. W tym celu wybierzmy wszystkie standardowe transakcje sprzedaży produktu o numerze 84598, a następnie przypiszmy każdemu rekordowi oznaczenie

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

informujące, czy zawiera numer klienta. Ostatnim krokiem będzie obliczenie średniej ceny jednostkowej dla obu utworzonych grup. Wymienione kroki implementuje kod zawarty w listingu 2.3.

Listing 2.3. Wyznaczanie średniej ceny jednostkowej produktu o numerze 84598 w zależności od występowania numeru klienta.

```
import numpy as np
produkt_84598_zwykła_sprzedaż = produkt_84598.loc[
    (produkt_84598["Quantity"] > 0) & (produkt_84598["UnitPrice"] > 0)].copy()

produkt_84598_zwykła_sprzedaż.loc[: , 'HasCustomerID'] = np.where(
    produkt_84598_zwykła_sprzedaż['CustomerID'].notna(),
    'Yes',
    'No')

print(produkt_84598_zwykła_sprzedaż.groupby('HasCustomerID').agg(
    ŚredniaCenaJednostkowa = ("UnitPrice", 'mean')))
```

Okazuje się, że średnia cena jednostkowa produktu o numerze 84598 wynosi 0.206 w grupie transakcji zawierających numer klienta oraz 0.410 w grupie transakcji, do których nie przypisano takiego numeru. Jest to cenna obserwacja, ponieważ sugeruje, że brakujące wartości w kolumnie „CustomerID" mogą być związane ze specyficznym charakterem transakcji. Wobec tego nie należy ich automatycznie ignorować ani usuwać bez wcześniejszej analizy.

Dotychczasowa eksploracja danych pozwoliła zidentyfikować istotną cechę zbioru „UCI Online Retail II": zawiera on wiele różnych typów transakcji, które nie zostały jawnie oznaczone. W kolejnym kroku rozszerzymy zatem ramkę danych „transakcje" o nową kolumnę opisującą rodzaj każdej transakcji. Klasyfikację przeprowadzimy na podstawie zestawu warunków odnoszących się do wartości w pozostałych kolumnach oraz wiedzy wynikającej z przeprowadzonej analizy danych. Listing 2.4 przedstawia wspomniany proces.

Listing 2.4. Rozszerzanie zbioru danych o nową kolumnę opisującą rodzaj przeprowadzonej transakcji.

```
warunki = [
    transakcje["InvoiceNo"].astype(str).str.startswith("C"),

    (transakcje["Quantity"] > 0) & (transakcje["UnitPrice"] > 0)
```

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

```
5.          & transakcje["CustomerID"].notna(),
6.
7.          (transakcje["Quantity"] > 0) & (transakcje["UnitPrice"] > 0)
8.          & transakcje["CustomerID"].isna(),
9.
10.         (transakcje["Quantity"] > 0) & (transakcje["UnitPrice"] == 0)
11.         & transakcje["CustomerID"].notna(),
12.
13.         (transakcje["Quantity"] > 0) & (transakcje["UnitPrice"] == 0)
14.         & transakcje["CustomerID"].isna(),
15.
16.         (transakcje["Quantity"] < 0) & (transakcje["UnitPrice"] == 0) ]
17.
18.     kategorie = [
19.         "anulowanie_bądź_zwrot",
20.         "standardowa_sprzedaż_klient",
21.         "sprzedaż_brak_klienta",
22.         "wydanie_bez_opłaty_klient",
23.         "wydanie_bez_opłaty_brak_klienta",
24.         "korekta_stanów_magazynowych" ]
25.
26.     transakcje.loc[:, "RodzajTransakcji"] = np.select(
27.         warunki, kategorie, default="inny")
```

Uwaga! Na tym etapie należy wykonać **ćwiczenie 1** zamieszczone w sekcji „Ćwiczenia samodzielne".

W ramach dalszej analizy zbioru danych warto również utworzyć kolumnę zawierającą wartość transakcji, obliczaną jako iloczyn ceny jednostkowej i liczby sztuk. Zgodnie z opisem zbioru „UCI Online Retail II" zamieszczonym w serwisie „Kaggle" ceny jednostkowe są wyrażone w funtach brytyjskich (GBP, ang. „British pound sterling"). Kod przedstawiony na listingu 2.5 rozszerza ramkę danych „transakcje" o nową kolumnę „WartośćTransakcji".

Listing 2.5. Rozszerzanie zbioru danych o nową kolumnę „WartośćTransakcji".

```
1.      transakcje.loc[:, 'WartośćTransakcji'] = \
2.                          transakcje['Quantity'] * transakcje['UnitPrice']
```

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

Uwaga! Na tym etapie należy wykonać **ćwiczenie 2** zamieszczone w sekcji „Ćwiczenia samodzielne".

Z perspektywy biznesowej istotną informacją jest występowanie sezonowości sprzedaży. W przedsiębiorstwach handlowych wzrost przychodów często obserwuje się w okresie poprzedzającym Boże Narodzenie. Sprawdźmy, czy podobna zależność występuje również w analizowanym zbiorze danych.

Biblioteka „pandas" wczytuje daty jako tekst, a dokładniej jako wartości typu „object". Dlatego w pierwszej kolejności należy przekonwertować wartości z kolumny „InvoiceDate" na typ przeznaczony do reprezentowania daty i czasu. Służy do tego funkcja „pandas.to_datetime". Po wykonaniu konwersji można odwoływać się do poszczególnych składowych daty, takich jak rok, miesiąc lub dzień. Implementację agregacji danych sprzedażowych według miesiąca przedstawia listing 2.6.

Listing 2.6. Pobieranie informacji o miesięcznej wysokości sprzedaży.

```
transakcje['InvoiceDate'] = pd.to_datetime(transakcje['InvoiceDate'])
print(transakcje['InvoiceDate'].dtype)

sprzedaż_miesięczna = (
    transakcje[transakcje['RodzajTransakcji'] == 'standardowa_sprzedaż_klient']
    .groupby(transakcje["InvoiceDate"].dt.month)
    .agg(Przychód=("WartośćTransakcji", "sum"))
    .reset_index()
    .rename(columns={"InvoiceDate": "Miesiąc"}))

print(sprzedaż_miesięczna)
```

Zawartość ramki danych „sprzedaż_miesięczna" potwierdza przypuszczenie, że sprzedaż wzrasta w okresie poprzedzającym Boże Narodzenie — najwyższy przychód odnotowano bowiem w listopadzie (2334153.422). Warto również przedstawić dane dotyczące miesięcznej sprzedaży w formie graficznej. Za pomocą bibliotek „seaborn" i „Matplotlib" można wygenerować przejrzysty wykres słupkowy, tak jak ma to miejsce na listingu 2.7.

Listing 2.7. Generowanie wykresu słupkowego przedstawiającego miesięczną wysokość sprzedaży.

```
import seaborn as sns
```

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

```
import matplotlib.pyplot as plt

plt.figure(figsize=(10, 5))
sns.barplot(data=sprzedaż_miesięczna, x="Miesiąc", y="Przychód")

plt.title("Przychód w poszczególnych miesiącach")
plt.xlabel("Miesiąc")
plt.ylabel("Przychód")
plt.show()
```

Przejdziemy teraz do zagadnień korelacji i autokorelacji, które należą do często wykorzystywanych elementów analizy danych. Choć zbiór „UCI Online Retail II" nie jest najlepszym przykładem do ilustrowania korelacji ze względu na niewielką liczbę kolumn (cech) oraz przewidywalność wyników, dla zachowania spójności pozostaniemy przy nim.

Przed przystąpieniem do obliczeń utworzymy nową ramkę danych agregującą informacje o klientach. Zgodnie z kodem przedstawionym na listingu 2.8 uwzględniamy wyłącznie transakcje oznaczone jako standardowa sprzedaż dla klienta. Warto również odnotować, że utworzona w ten sposób ramka danych nie zawiera brakujących wartości.

Listing 2.8. Tworzenie ramki danych agregującej informacje o klientach.

```
sprzedaż = transakcje.loc[transakcje['RodzajTransakcji'] == \
                    'standardowa_sprzedaż_klient'].copy()

print(sprzedaż.isna().sum()) #wartości brakujące nie występują

df_klienci = sprzedaż.groupby("CustomerID").agg(
    Przychód=("WartośćTransakcji", "sum"),
    Liczba_Zamówień=("InvoiceNo", "nunique"),
    Sumaryczna_Ilość=("Quantity", "sum"),
    Liczba_Różnych_Produktów=("StockCode", "nunique"),
    Średnia_Cena_Jednostkowa=("UnitPrice", "mean"),
    Pierwszy_Zakup=("InvoiceDate", "min"),
    Ostatni_Zakup=("InvoiceDate", "max") )

data_koniec_okresu = sprzedaż["InvoiceDate"].max() + pd.Timedelta(days=1)
```

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

```
#wynik: 2011-12-10 12:50:00

df_klienci["Dni_Od_Ostatniego_Zakupu"] = (
    data_koniec_okresu - df_klienci["Ostatni_Zakup"]).dt.days

df_klienci["Dni_Aktywności_Klienta"] = (
    df_klienci["Ostatni_Zakup"] - df_klienci["Pierwszy_Zakup"]).dt.days + 1

df_klienci["Średnia_Wartość_Zamówienia"] = (
    df_klienci["Przychód"] / df_klienci["Liczba_Zamówień"])

print(df_klienci.head())
```

Dodatkowo ramka danych „df_klienci" została rozszerzona o kolumny zawierające informacje o liczbie dni od ostatniego zakupu, liczbie dni pomiędzy pierwszym a ostatnim zakupem oraz średniej wartości zamówienia.

Przypomnijmy, że współczynnik korelacji Pearsona, do którego odnosimy się, mówiąc o korelacji, oblicza się między dwiema zmiennymi ilościowymi (wartościami numerycznymi). W przypadku analizy wielu zmiennych współczynniki korelacji zestawia się w postaci macierzy korelacji. Macierz tę często przedstawia się graficznie za pomocą mapy cieplnej, na której kolor odpowiada wartości współczynnika korelacji.

Ćwiczenie numer 3 polega na obliczeniu macierzy korelacji dla zmiennych numerycznych znajdujących się w ramce danych „df_klienci" oraz na przedstawieniu otrzymanego wyniku w formie mapy cieplnej.

Uwaga! Na tym etapie należy wykonać **ćwiczenie 3** zamieszczone w sekcji „Ćwiczenia samodzielne".

Oprócz korelacji pomiędzy różnymi zmiennymi możemy również analizować autokorelację, ponieważ eksplorowane dane dotyczą procesów zachodzących w czasie. W tym przypadku interesuje nas zależność między przychodem w bieżącym miesiącu a przychodem odnotowanym w miesiącu poprzednim. Proces tworzenia szeregu czasowego miesięcznych przychodów oraz sposób obliczania autokorelacji dla opóźnienia wynoszącego jeden miesiąc przedstawiono na listingu 2.9.

Listing 2.9. Obliczanie autokorelacji dla opóźnienia wynoszącego jeden miesiąc.

```
sprzedaż = transakcje.loc[transakcje['RodzajTransakcji'] == \
```

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

```
2.      'standardowa_sprzedaż_klient'].copy()
3.      # Przychód miesięczny to szereg czasowy
4.      przychód_miesięczny= (
5.          sprzedaż
6.          .set_index("InvoiceDate")
7.          .resample("MS")["WartośćTransakcji"].sum() #Grupuj według miesięcy
8.          .reset_index()) #Anulowanie instrukcji set_index("InvoiceDate")
9.
10.     przychód_miesięczny["Przychód_Sprzed_1M"] = \
11.             przychód_miesięczny["WartośćTransakcji"].shift(1)
12.
13.     print(przychód_miesięczny.head(7))
14.
15.     pm = przychód_miesięczny.dropna(subset=
16.                             ["WartośćTransakcji", "Przychód_Sprzed_1M"])
17.     auto_kor_1m = \
18.       przychód_miesięczny["WartośćTransakcji"].corr(pm["Przychód_Sprzed_1M"])
19.
20.     print("Autokorelacja (Opóźnienie 1 miesiąc):", auto_kor_1m) #wynik: 0.527
```

Za pomocą metody „DataFrame.shift" tworzymy nową kolumnę przechowującą wartość przychodu z poprzedniego miesiąca. Metoda ta przesuwa wartości w wybranej kolumnie o liczbę pozycji określoną za pomocą argumentu. Przykładowo, przychód sprzed sześciu miesięcy można uzyskać, wywołując metodę „shift" z argumentem równym 6.

W wyniku przesunięcia na początku szeregu pojawiają się brakujące wartości. Przed obliczeniem autokorelacji, czyli korelacji pomiędzy wyrazem szeregu a wyrazem go poprzedzającym o zadaną liczbę cykli, należy usunąć wiersze zawierające braki danych.

Wartość autokorelacji dla opóźnienia wynoszącego jeden miesiąc, równa 0.527, wskazuje na umiarkowaną dodatnią zależność między przychodami w kolejnych miesiącach. Oznacza to, że miesiące charakteryzujące się relatywnie wysokim przychodem często są poprzedzane miesiącami o również wysokim przychodzie. Natomiast po miesiącach o niższym przychodzie częściej występują kolejne miesiące, w których przychód maleje. Warto odnotować, że zależność ta nie jest jednak silna ani jednoznaczna.

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

Uwaga! Na tym etapie należy wykonać **ćwiczenie 4** zamieszczone w sekcji „Ćwiczenia samodzielne".

Ćwiczenia samodzielne

Ćwiczenie nr 1

Jednym z rodzajów transakcji występujących w zbiorze danych „UCI Online Retail II" jest wydanie produktu klientowi bez pobrania opłaty. Kod przedstawiony na listingu 2.4 przypisuje klasę „wydano_bez_opłaty_klient" transakcjom, dla których podano wartość „CustomerID", wartość „Quantity" jest większa od zera, a wartość „UnitPrice" wynosi zero.

Sprawdź, czy transakcje należące do klasy „wydano_bez_opłaty_klient" mogą dotyczyć gratisów lub próbek dołączanych do zakupów. Jeżeli na tej samej fakturze znajdują się zarówno produkty płatne, jak i produkt bezpłatny, taka interpretacja staje się dość prawdopodobna.

W pierwszej kolejności utwórz listę unikatowych numerów faktur zawierających transakcje należące do klasy „wydano_bez_opłaty_klient". Następnie wybierz z ramki danych „transakcje" wszystkie rekordy dotyczące faktur znajdujących się na utworzonej liście. Posortuj otrzymane dane według kolumn „InvoiceNo" i „UnitPrice" – w podanej kolejności. Na koniec wyświetl następujące kolumny wynikowej ramki danych: „InvoiceNo", „Description", „Quantity", „UnitPrice" oraz „CustomerID". Przeanalizuj wyniki i zweryfikuj słuszność postawionej hipotezy. [**Powrót**]

Ćwiczenie nr 2

Korzystając z konstrukcji „groupby().agg()", utwórz ramkę danych zawierającą podstawowe statystyki opisujące każdy rodzaj transakcji występujący w ramce danych „transakcje". Dla każdej kategorii transakcji wyznacz:

- liczbę wszystkich transakcji — funkcja agregująca „size",
- liczbę unikatowych faktur — funkcja agregująca „nunique",
- łączną wartość kolumny „Quantity" — funkcja agregująca „sum",
- łączną wartość transakcji — funkcja agregująca „sum",
- średnią cenę jednostkową — funkcja agregująca „mean",
- medianę ceny jednostkowej — funkcja agregująca „median".

Skorzystaj z podanego na listingu 2.10 wzorca konstrukcji „groupby().agg()". [**Powrót**]

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

Listing 2.10. Wzorzec konstrukcji „groupby().agg()”.

```
data_frame.groupby("KolumnaOkreślającaGrupy").agg(
  NazwaNowejKolumny=("IstniejącaKolumna", "funkcja_agregująca"),
  NazwaNowejKolumny=("IstniejącaKolumna ", "funkcja_agregująca")]
```

Ćwiczenie nr 3

Wyznacz macierz korelacji dla ramki danych „df_klienci”, utworzonej na podstawie listingu 2.8, i zapisz ją w obiekcie o nazwie „m_korelacji”. Następnie uruchom kod przedstawiony na listingu 2.11, przeanalizuj otrzymaną mapę cieplną i odpowiedz na pytanie: które dwie kolumny wykazują najsilniejszą korelację dodatnią, a które ujemną? [**Powrót**]

Listing 2.11. Tworzenie mapy cieplnej przedstawiającej macierz korelacji.

```
import seaborn as sns
import matplotlib.pyplot as plt

sns.set_theme(context='talk',style="whitegrid")

plt.figure(figsize=(10, 8))
sns.heatmap(
   np.tril(m_korelacji.to_numpy()), #np.tril -> macierz trójkątna dolna
   annot=True,   #Wyświetlenie wartości korelacji
   fmt=".2f",       #Liczba miejsc po przecinku
   cmap="coolwarm",
   center=0,      #Wartość środkowa/neutralna (poprawne kolorowanie)
   square=True,
   xticklabels= m_korelacji.columns,
   yticklabels= m_korelacji.columns)

plt.title("Macierz korelacji")
plt.show()
```

Ćwiczenie nr 4

Oblicz współczynnik autokorelacji miesięcznego przychodu dla opóźnienia wynoszącego 12 miesięcy, korzystając z szeregu czasowego utworzonego na listingu 2.9. Następnie zinterpretuj otrzymaną wartość. [**Powrót**]

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

Pytania pomocnicze

- Wyjaśnij pojęcie korelacji oraz współczynnika korelacji Pearsona. Podaj wzór oraz omów interpretację otrzymanych wartości.
- Wyjaśnij pojęcie autokorelacji. Podaj wzór oraz omów interpretację otrzymanych wartości.

Podsumowanie

W ramach laboratorium kontynuowano eksplorację zbioru danych „UCI Online Retail II" oraz rozszerzono analizę o zagadnienia związane z agregacją danych, sezonowością, korelacją i autokorelacją. W szczególności:

- Zidentyfikowano różne rodzaje transakcji występujące w zbiorze.
- Wykorzystano konstrukcję „groupby().agg()" do wyznaczenia podstawowych statystyk opisujących sprzedaż.
- Zagregowano przychody według miesięcy oraz przeanalizowano występowanie sezonowości sprzedaży w okresie poprzedzającym Boże Narodzenie.
- Obliczono macierz korelacji dla zmiennych opisujących klientów oraz przedstawiono ją w formie mapy cieplnej.
- Utworzono szereg czasowy miesięcznych przychodów i obliczono autokorelację dla różnych wartości opóźnienia.

Realizacja laboratorium pozwoliła zdobyć praktyczne umiejętności związane z eksploracją, analizą i agregacją danych oraz rozszerzaniem zbioru danych o nowe zmienne. Czytelnik nauczył się również analizować sezonowość sprzedaży, interpretować macierze korelacji oraz wykorzystywać wizualizacje do przedstawiania zależności między zmiennymi.

Literatura

Literatura podstawowa.

1. Hyndman, R.J., Athanasopoulos, G., Garza, A., Challu, C., Mergenthaler, M., & Olivares, K.G., *Forecasting: Principles and Practice, the Pythonic Way*. OTexts: Melbourne, Australia 2026. Available at: **OTexts.com/fpppy.** Rozdział 2, w szczególności sekcja 2.8.

Fundusze Europejskie dla Rozwoju Społecznego | Rzeczpospolita Polska | Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00

2. Bruce P., Bruce A., Gedeck P., *Practical Statistics for Data Scientists. 50+ Essential Concepts Using R and Python. 2nd Edition,* O'Reilly Media, Inc., 2020. Rozdział 1 – Correlation.

Literatura uzupełniająca.

1. McKinney W., *Python for Data Analysis. 3rd Edition,* O'Reilly Media, Inc., 2022.

Fundusze Europejskie dla Rozwoju Społecznego
Rzeczpospolita Polska
Dofinansowane przez Unię Europejską

Projekt współfinansowany ze środków Unii Europejskiej w ramach: FUNDUSZE EUROPEJSKIE DLA ROZWOJU SPOŁECZNEGO 2021-2027 (FERS) "POLLUB z nami nowoczesne technologie" FERS.01.05-IP.08-0319/23-00